强化学习内容推导—1.

- 多臂老虎机（MAB）：无状态的强化学习.

$\langle A, R \rangle$ $\begin{cases} A & \text{动作集} \quad \{a_1, \cdots, a_K\} \quad K\text{根拉杆} \\ R & \text{奖励概率分布} \quad R(r|a_i) \end{cases}$

目标：$\max \sum_{t=1}^{T} r_t$，$r_t \sim R(\cdot|a_t)$

动作 a 期望奖励	$Q(a) = E_{r\sim R(\cdot\|a)}[r]$
最优 ~	$Q^* = \max_{a\in A} Q(a)$
懊悔	$R(a) = Q^* - Q(a)$
累积懊悔	$\sigma_R = \sum_{t=1}^{T} R(a_t)$

$\forall a \in A$，初始 $N(a)=0$（计数器） $\hat{Q}(a)=0$（期望奖励估值）

for $t = 1 \to T$ do:

选取拉杆 a_t，得到奖励 r_t，

更新计数器 $N(a_t)$ ++

更新期望奖励估值：$\hat{Q}(a_t) = \hat{Q}(a_t) + \frac{1}{N(a_t)}[r_t - \hat{Q}(a_t)]$

end for.

↓ 增量式更新

$$Q_k = \frac{1}{k}\sum_{i=1}^{k} r_i$$
$$= \frac{1}{k}\left(\sum_{i=1}^{k-1} r_i + r_k\right)$$
$$= \frac{1}{k}[r_k + (k-1)Q_{k-1}]$$
$$= Q_{k-1} + \frac{1}{k}[r_k - Q_{k-1}]$$

- 选择的策略
  - ε-贪心策略：$\varepsilon \to$ 探索 $\to$ 可令 ε 随时间递减

$$a_t = \begin{cases} \arg\max_{a\in A} \hat{Q}(a) & 1-\varepsilon \text{ 概率} \\ A \text{ 中随机选择} & \varepsilon \text{ 概率} \end{cases}$$

夸克扫描王
极速扫描，就是高效

强化学习内容推导—2.

- 选择的策略.
  - 上置信界算法.

    引理：霍夫丁不等式：

    令 $X_1, \cdots X_n$ 为 n 个独立同分布随机变量，取值范围为 $[0, 1]$

    经验期望为 $\bar{x}_n = \frac{1}{n}\sum_{j=1}^{n} x_j$，则有：

    $$P\{E[X] \geq \bar{x}_n + u\} \leq e^{-2nu^2}$$

    u 代表不确定性度量

  代入，$\bar{x}_t = \hat{Q}_t(a)$，$u = \hat{U}_t(a)$，令 $p = e^{-2nu^2}$

  根据不等式，$P\{Q_t(a) < \hat{Q}_t(a) + \hat{U}_t(a)\} > 1-p$，即以 1-p 概率成立 (p很小时大概率成立)

  选期望奖励上界最大的动作 即 $a = \text{argmax}[\hat{Q}(a) + \hat{U}(a)]$

  由 $p = e^{-2nu^2}$ 反解得 $\hat{U}_t(a) = \sqrt{\frac{-\log p}{2N_t(a)}}$

  - 汤普森采样算法

    对动作及奖励采样，用 Beta 概率分布解算.

第三章 马尔可夫决策过程.

- ~~随机过~~ 马尔可夫性质：当且仅当某一时刻状态只取决于上一时刻状态.

  即：$P(S_{t+1}|S_t) = P(S_{t+1}|S_1, \cdots, S_t)$

- 马尔可夫过程（马尔可夫链）.

  用 $<S, P>$ 描述，S 为有限数量的状态集合，P 为状态转移矩阵.

$$P = \begin{bmatrix} P(s_1|s_1) & \cdots & P(s_n|s_1) \\ \vdots & & \vdots \\ P(s_1|s_n) & \cdots & P(s_n|s_n) \end{bmatrix}$$

第 i 行 j 列的元素 $P(s_j|s_i) = P(S_{t+1} = s_j | S_t = s_i)$ 表示由 s_i 转移到 s_j 的概率

夸克扫描王 极速扫描，就是高效

RL —— 3.

- 马尔可夫奖励过程. $<S, P, r, \gamma>$

  S：有限状态集

  P：状态转移矩阵

  r：奖励函数

  γ：折扣因子.

G_t：回报　　$G_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k}$

（对应某条序列）

$V(s)$：状态的价值. 价值函数.

$$V(s) = E[G_t | S_t = s]$$
$$= E[R_t + \gamma R_{t+1} + \cdots | S_t = s]$$
$$= E[R_t + \gamma G_{t+1} | S_t = s].$$
$$= E[R_t + \gamma V(S_{t+1}) | S_t = s].$$

$$\therefore V(s) = r(s) + \gamma \sum_{s' \in S} p(s'|s) V(s').$$

贝尔曼方程. 写为矩阵形式即：

$$V = \mathcal{R} + \gamma P V$$

得到解析解 $V = (I - \gamma P)^{-1} R$

以上复杂度为 $O(n^3)$，只适用于很小的马尔可夫奖励过程.

- 马尔可夫决策过程. (MDP)　$<S, A, P, r, \gamma>$

策略：π　　$\pi(a|s) = P(A_t = a | S_t = s)$

在策略 π 下在状态 s 执行策略 a 得到的期望回报：$Q^\pi(s,a) = E_\pi[G_t | S_t = s, A_t = a]$

又称为动作价值函数.

状态价值函数和动作价值函数的关系：$V^\pi(s) = \sum_{a \in A} \pi(a|s) Q^\pi(s,a)$

$$Q^\pi(s,a) = r(s,a) + \gamma \sum_{s' \in S} p(s'|s,a) V^\pi(s')$$

$r(s,a)$：当前状态奖励.　　$p(s'|s,a) V^\pi(s')$：未来转移到 s' 的预测奖励.

夸克扫描王
极速扫描，就是高效

RL - 4

贝尔曼期望方程：

$$V^{\pi}(s) = E_{\pi}[R_t + \gamma V^{\pi}(S_{t+1}) \mid S_t = s]$$

$$= \sum_{a \in A} \pi(a|s)\left(r(s,a) + \gamma \sum_{s' \in S} p(s'|s,a) V^{\pi}(s')\right)$$

$$Q^{\pi}(s,a) = E_{\pi}[R_t + \gamma Q^{\pi}(S_{t+1}, A_{t+1}) \mid S_t = s, A_t = a]$$

$$= r(s,a) + \gamma \sum_{s' \in S} p(s'|s,a) \underbrace{\sum_{a' \in A} \pi(a'|s') Q^{\pi}(s',a')}_{V^{\pi}(s')}$$

（即引入动作后的贝尔曼方程）

蒙特卡洛方法（统计方法）

用策略采样再取均值，

$$V^{\pi}(s) = E_{\pi}[G_t | S_t = s] \approx \frac{1}{N} \sum_{i=1}^{N} G_t^{(i)}$$

流程：1. 用策略 π 采样若干序列。

$$s_0^{(i)} \xrightarrow{a_0^{(i)}} r_0^{(i)}, \quad s_1^{(i)} \xrightarrow{a_1^{(i)}} r_1^{(i)}, \quad \cdots$$

2. 对每个序列进行操作。

更新状态 s 的计数器 $N(s) \leftarrow N(s) + 1$

更新 s 的总回报 $M(s) \leftarrow M(s) + G_t$。

3. 每个状态的价值估计为回报的平均值。

$$V(s) = \frac{M(s)}{N(s)}$$

其中当 $N(s) \to \infty$，$V(s) \to V^{\pi}(s)$

增量更新：$N(s)++$

$$V(s) \leftarrow V(s) + \frac{1}{N(s)}(G - V(s))$$

$$V_{(s)}^{(n)} = \frac{1}{N(s)} \sum_{i=1}^{N} G_t^{(i)}$$

$$= \frac{1}{N(s)}\left(\sum_{i=1}^{N-1} G_t^{(i)} + G_t^{(n)}\right)$$

$$= \frac{1}{N(s)}\left[(n-1) V_{(s)}^{(n-1)} + G_t^{(n)}\right]$$

$$= V_{(s)}^{(n-1)} + \frac{1}{N(s)}\left(G_t^{(n)} - V_{(s)}^{(n-1)}\right)$$

占用度量：

前置节点被访问的概率可能影响后方节点。

定义 MDP 的初始状态分布为 $V_0(s)$

用 $P_t^{\pi}(s)$ 表示采取策略 π 使得智能体在 t 时刻状态为 s 的概率。

$$P_0^{\pi}(s) = V_0(s).$$

夸克扫描王
极速扫描，就是高效

RL-5.

于是定义策略的状态访问分布.

$$\nu^{\pi}(s) = (1-\gamma)\sum_{t=0}^{\infty}\gamma^t P_t^{\pi}(s)$$

用来使加和为1的归一化因子.

$$\nu^{\pi}(s') = (1-\gamma)\nu_0(s') + \gamma\int P(s'|s,a)\pi(a|s)\nu^{\pi}(s)\,ds\,da$$

策略的占用度量定义为:

$$\rho^{\pi}(s,a) = (1-\gamma)\sum_{t=0}^{\infty}\gamma^t P_t^{\pi}(s)\pi(a|s).$$

表示动作状态对(s,a)被访问的概率.

$$\rho^{\pi}(s,a) = \nu^{\pi}(s)\pi(a|s).$$

定理1: π_1和π_2若都满足 $\rho^{\pi_1} = \rho^{\pi_2}$ $\Leftrightarrow$ $\pi_1 = \pi_2$.

定理2: 对合法占用度量ρ, 策略为:

$$\pi_\rho = \frac{\rho(s,a)}{\sum_{a'}\rho(s,a')}$$

最优策略.

$$V^*(s) = \max_{\pi} V^{\pi}(s), \quad \forall s \in S$$

$$Q^*(s,a) = \max_{\pi} Q^{\pi}(s,a), \quad \forall s \in S, a \in A$$

$$Q^*(s,a) = r(s,a) + \gamma\sum_{s'\in S} P(s'|s,a)V^*(s')$$

$$V^*(s) = \max_{a\in A} Q^*(s,a).$$

同理写最优方程即可

夸克扫描王
极速扫描，就是高效

RL-6.

动态规划（DP）.

- 策略迭代
  - 策略评估 → Bellman 期望方程、$\pi_0 \to V_{\pi_0} \xrightarrow{收} \pi_1 \to V_{\pi_1} \xrightarrow{收} \cdots$
  - ↓
  - 策略提升.
- 价值迭代 ⟶ Bellman 方程，最后贪心得策略 π

策略评估（固定 π）

贝尔曼期望方程：$V^{\pi}(s) = \sum_{a \in A} \pi(a|s)\left(r(s,a) + \gamma \sum_{s' \in S} p(s'|s,a) V^{\pi}(s')\right)$

$$V^{k+1}(s) = \sum_{a \in A} \pi(a|s)\left(r(s,a) + \gamma \sum_{s' \in S} p(s'|s,a) V^{k}(s')\right)$$

∴ $V^k = V^{\pi}$ 是方程的不动点，最后会逐渐收敛.

若某一轮的 $\max_{s \in S} |V^{k+1}(s) - V^k(s)|$ 非常小，则提前结束迭代.

策略提升

使用策略评估得到当前策略的状态价值函数.

若存在一个确定性策略 π'，满足 $Q^{\pi}(s, \pi'(s)) \geq V^{\pi}(s)$

∴ $\forall$ 状态 s 下，有 $V^{\pi'}(s) \geq V^{\pi}(s)$.

（策略提升定理）⇒ 贪心地在每个状态选择动作价值最大的动作

$$\pi'(s) = \arg\max_a Q^{\pi}(s,a) = \arg\max_a \{r(s,a) + \gamma \sum_{s'} p(s'|s,a) V^{\pi}(s')\}$$

证明：$V^{\pi}(s) \leq Q^{\pi}(s, \pi'(s))$

$$= E_{\pi'}[R_t + \gamma V^{\pi}(S_{t+1}) | S_t = s]$$

$$\leq E_{\pi'}[R_t + \gamma Q^{\pi}(S_{t+1}, \pi'(S_{t+1})) | S_t = s]$$

$$= E_{\pi'}[R_t + \gamma R_{t+1} + \gamma^2 V^{\pi}(S_{t+2}) | S_t = s]$$

$$\leq \cdots$$

$$\leq E_{\pi'}[R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \cdots | S_t = s]$$

$$= V^{\pi'}(s)$$

夸克扫描王
极速扫描，就是高效

RL-7

策略迭代算法

$\pi^0 \xrightarrow{\text{评}} V^{\pi^0} \xrightarrow[\text{(收敛后)}]{\text{提}} \pi' \xrightarrow{\text{评}} V^{\pi'} \to \cdots \xrightarrow{\text{提}} \pi^*$

迭代流程：（V^{π^0} 如更新地图上的每个状态的价值）

※ 随机初始化策略 $\pi(s)$ 和价值函数 $V(s)$.

while $\Delta > \theta$ do：

$\Delta \leftarrow 0$

对每个状态 $s \in S$：

$v \leftarrow V(s)$

$V(s) \leftarrow r(s, \pi(s)) + \gamma \sum_{s'} P(s'|s, \pi(s)) V(s')$

$\Delta \leftarrow \max(\Delta, |v - V(s)|)$

end while

$\pi_{old} \leftarrow \pi$

对每个状态 $s \in S$：

$\pi(s) \leftarrow \arg\max_a r(s,a) + \gamma \sum_{s'} P(s'|s,a) V(s')$

若 $\pi_{old} = \pi$，则停止算法并返回 V 和 π

价值迭代算法

$$V^{k+1}(s) = \max_{a \in A} \{ r(s,a) + \gamma \sum_{s' \in S} P(s'|s,a) V^k(s') \}$$

由终点向前推导

定义贝尔曼算子 T：

$$V^{k+1}(s) = T V^k(s) = \boxed{\quad}$$

引入压缩算子：

若 O 是一个算子，如满足 $\|OV - OV'\|_q \leq \|V - V'\|_q$ 条件，我们称 O 是一个压缩算子，其中 $\|x\|_q$ 表示 x 的 L_q 范数，包括将用到的无穷范数 $\|x\|_\infty = \max_i |x_i|$

下面证明当 $\gamma < 1$ 时，贝尔曼最优算子 T 是一个 γ-压缩算子

$$\|TV - TV'\|_\infty = \max_s \left| \max_a \{\cdots\} - \max_a \{\cdots\} \right|$$

$$\leq \max_{s,a} \left| \sum_{s' \in S} \gamma P(s'|s,a)(V(s') - V'(s')) \right|$$

$$\leq \gamma \max_{s,a} \sum_{s' \in S} P(s'|s,a) |V(s') - V'(s')| = \gamma \|V - V'\|_\infty$$

夸克扫描王
极速扫描，就是高效

RL-8

设 V' 为最优价值函数 V^*，于是有：

$$\|V^{k+1}-V^*\|_\infty = \|\mathcal{T}V^k-\mathcal{T}V^*\|_\infty \le \gamma\|V^k-V^*\|_\infty \le \gamma^2\|V^{k-1}-V^*\| \le \cdots \le \gamma^{k+1}\|V^0-V^*\|_\infty$$

在 $\gamma<1$ 情况下，随迭代次数 $\uparrow$，V^k 会越来越接近 V^*

收敛性得证

无模型 RL

时序差分算法：对于现实，马尔可夫决策的状态转移概率是无法写出的，于是引出了无模型强化学习。

蒙特卡洛方法：

$$V(s_t) \leftarrow V(s_t) + \frac{1}{N(s)}[G_t - V(s_t)]$$

$$\Downarrow$$

$$V(s_t) \leftarrow V(s_t) + \alpha[r_t + \gamma V(s_{t+1}) - V(s_t)]$$

其中 $r_t + \gamma V(s_{t+1}) - V(s_t)$ 称为时序差分误差。

∴每进行一步就更新一下 $V(s)$ 不必像蒙特卡洛方法一样进行完一轮才更新

- Sarsa 算法：

$$Q(s_t,a_t) \leftarrow Q(s_t,a_t) + \alpha[r_t + \gamma Q(s_{t+1},a_{t+1}) - Q(s_t,a_t)]$$

用贪婪算法在某状态下选取动作价值最大的动作。

即 $\arg\max_a Q(s,a)$

① 广义策略迭代的估计（不完全追时估算）

② 为防止某些状态对由于贪婪算法而一直不被取值，采用 ε-贪婪。

Sarsa 流程：1. 初始化 $Q(s,a)$

2. for 序列 $e = 1 \to E$ do

得到初始状态 s，

~~用 ε-greedy 策略根据 Q 选择当前状态 s 下的动作 a。~~

~~在下一个循环！这里写错了很多~~

夸克扫描王 极速扫描，就是高效

RL-9.

for ~~回合~~ t: 1→T do:

得到环境反馈 r, s'

用 ε-greedy 策略根据 Q 选择当前状态 s' 下的动作 a'.

$Q(s,a) \leftarrow Q(s,a) + \alpha[r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$

$s \leftarrow s'$, $a \leftarrow a'$

endfor.

endfor.

~~时序~~ Sarsa:

◦ 多步 ~~Sarsa~~ 算法 (Sarsa 升级版).

蒙特卡洛方法. 无偏但方差大(随机取样的序列).

时序差分算法. 有偏:用到下一状态的价值估计而非真正价值.
方差小:只关注一步的状态转移

⇒ 引出的多步时序差分算法

$G_t = r_t + \gamma Q(s_{t+1}, a_{t+1})$

替换为 $G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \gamma^n Q(s_{t+n}, s_{t+n})$.

注:即把只关注后一步扩展为关注之后多步.

更新公式: $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma r_{t+1} + \cdots + \gamma^n Q(s_{t+n}, a_{t+n}) - Q(s_t, a_t)]$

◦ Q-Learning

更新方式: $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[R_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$

对比
- SARSA (在线): 预定下一刻要走的真实动作 a', 用真实路径更新 Q 值.
- Q-Learning (离线): 用 s' 下理论最优动作进行更新价值,但下一步动作仍用 ε-贪婪另行选择,有可能进行探索.

夸克扫描王
极速扫描,就是高效

RL-10

行为策略：采样数据的～
目标策略：用数据来更新的～
⇒ 在线策略学习：=
离线策略学习：≠

离线策略学习	离线强化学习
有一定样本库，且不断交互中把最新经验放回经验回放池中	有给定样本集，不允许和环境持续交互扩大样本集。

对 Q-Learning 的收敛性证明：

引理：假设随机过程 Δ_t 形式为 $\Delta_{t+1}(x) = (1-\alpha_t(x))\Delta_t(x) + \alpha_t(x)F_t(x)$.

若满足以下条件，则将收敛至 0：

(1) $\sum_t \alpha_t(x) = \infty$

(2) $\sum_t \alpha_t^2(x) < \infty$

(3) $\|E[F_t(x)]\|_Q \le \gamma \|\Delta_t\|_Q$，其中 $\gamma < 1$

(4) $\mathrm{var}(F_t(x)) \le C(1+\|\Delta_t\|_Q^2)$，其中 $C > 0$.

在 t 时间步给定数据 (s, a, r, s')，Q-Learning 原来的更新公式可写为：

$$Q_{t+1}(s,a) = Q_t(s,a) + \alpha_t(s,a)\left[r + \gamma \max_{b\in A} Q_t(s',b) - Q_t(s,a)\right]$$

↓ 令其与时间有关，且 $0 < \alpha \le 1$

↓ 假设 $\sum_t \alpha_t(s,a) = \infty$

↓ $\sum_t \alpha_t^2(s,a) < \infty$

↓ 等式左右减 $Q^*(s,a)$，令 $\Delta_t(s,a) = Q_t(s,a) - Q^*(s,a)$

$$\Delta_{t+1}(s,a) = (1-\alpha_t(s,a))\Delta_t(s,a) + \alpha_t(s,a)\underbrace{\left[r + \gamma \max_{b\in A} Q_t(s',b) - Q^*(s,a)\right]}_{\text{定义为 } F_t(s,a)}$$

$$\therefore E[F_t(s,a)] = \underbrace{r(s,a) + \gamma \sum_{y\in S} p(y|s,a) \max_{b\in A} Q_t(y,b)}_{\text{定义为算子 } HQ_t(s,a)} - Q^*(s,a).$$

即有 $E[F_t(s,a)] = HQ_t(s,a) - Q^*(s,a)$

而根据定义，$Q^*(s,a)$ 应为 $HQ_t^*(s,a)$ 的不动点

∴ 可以写为 $Q^*(s,a) = HQ_t^*(s,a)$.

夸克扫描王
极速扫描，就是高效

RL-11

∴ 写为：$E[F_t(s,a)] = \mathcal{H}Q^*_t(s,a) - \mathcal{H}Q^*(s,a)$

可以证明 $\mathcal{H}$ 是一个压缩算子。

$$\|\mathcal{H}Q - \mathcal{H}Q'\|_\infty = \max_{s,b} \left|\gamma \sum_{y} p(y|s,a)(Q_y - Q'_y)\right|$$

$$\leq \gamma \max_{s,b} \sum_{y} p(y|s,a)\left|Q_y - Q'_y\right|$$

$$= \gamma \|Q - Q'\|_\infty = \gamma \|\Delta_t\|_\infty$$

方差：

$$Var[F_t(s,a)] = E[(F_t(s,a) - E[F_t(s,a)])^2]$$

$$= E\left[\left[r + \gamma \max_{b\in A} Q_t(s',b) - Q^*(s,a) - \mathcal{H}Q_t(s,a) + \mathcal{H}Q^*(s,a)\right]^2\right]$$

$$= E\left[\left[r + \gamma \max_{b\in A} Q_t(s',b) - \mathcal{H}Q_t(s,a)\right]^2\right]$$

$$= Var\left[r + \gamma \max_{b\in A} Q_t(s',b)\right]$$

∵ r 有界.

∴ $\exists C$, s.t. $Var[F_t(s,a)] \leq C(1 + \|\Delta_t\|_\infty^2)$

∴ 据引理，Δ_t 能收敛至 0，即 Q_t 收敛至 Q^*.

第六章 Dyna-Q 算法（基于模型的 RL）.

基于模型的强化学习：策略迭代、价值迭代

无模型的强化学习：Sarsa、Q-Learning

~~可否筛选未来收敛的序列进行重复训练（如值分段式的学习率）~~

Dyna-Q 相对 Q-Learning 多维护了一个历史观测序，随机从序中采样，读取虚拟奖励，虚拟下一状态并进行 Q-Learning 更新，提高样本利用率。

但存在弊端：1. 环境本身随机，模型只记住了其中一条结果。

2. 模型误差造成错误数据被反复训练！

前期探索数据不稳定，在执行一段时间后能为 q-planning？

夸克扫描王
极速扫描，就是高效

RL-12

第七章 DQN算法

Q-Learning 用矩阵存储状态，只适用于小场景且状态动作离散。但处理图像时无法存储如此数量级的表格，于是用参数化函数 Q_θ 拟合 Q 值表格数据

采用 CartPole 环境 （倒立摆）

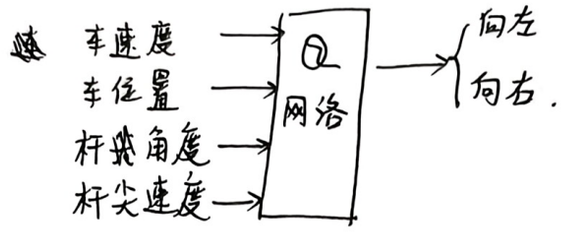

回顾 Q-Learning ： $Q(s,a) \leftarrow Q(s,a) + \alpha\left[r + \gamma \max_{a' \in A} Q(s',a') - Q(s,a)\right]$

即 $\Rightarrow$ 让 $Q(s,a)$ 学习 $r + \gamma \max_{a' \in A} Q(s',a')$

$$\therefore \quad w^* = \arg\min_w \frac{1}{2N} \sum_{i=1}^{N} \left[Q_w(s_i,a_i) - \left(r_i + \gamma \max_{a'} Q_w(s_i',a')\right)\right]^2$$

于是扩展为 DQN

由于 DQN 为离线策略算法，收集数据时采用 ε-贪婪平衡探索 & 利用，将数据存储用于之后训练，于是引出 2 重要模块，经验回放 & 目标网络

经验回放

对比 Dyna-Q， 回放：重放历史片段，无法对路径串联起关系

Dyna：重开一局完整模拟

目标网络

DQN 目标是让 Q_w 逼近 $r + \gamma \max_{a' \in A} Q(s',a')$，但目标本身就包含神经网络输出，更新参数同时目标也在变，易造成不稳定。于是提出使用两套 Q 网络，用目标网络固定 Q

$Q_w(s,a)$ ：原来的训练网络

$Q_{w^-}(s,a)$ ：目标网络

损失函数： $\frac{1}{2}\left[Q_w(s,a) - (r + \gamma \max_{a'} Q_{w^-}(s',a'))\right]^2$

$Q_{w^-}(s,a)$ 的参数每隔 C 步与 $Q_w(s,a)$ 同步一次，即使用不同更新频率

夸克扫描王
极速扫描，就是高效

RL-13.

以图像为输入的DQN，DQN通常将最近几帧图像一起作为输入，从而感知环境动态性.

DQN改进算法

Double DQN

普通DQN会导致对Q的过高估计 优化目标为：$r + \gamma \max_{a} Q_{w^-}(s', a')$.

也可写为以下形式：$Q_{w^-}\left(s', \arg\max_{a} Q_{w^-}(s', a')\right)$

由于对神经网络估计存在偏差，且选取最优动作后计算价值.

$a^* = \arg\max_{a} Q_w(s', a') \longrightarrow Q_{w^-}(s', a^*)$

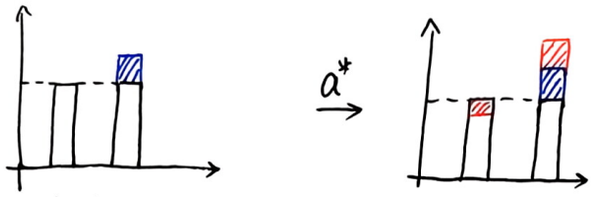

⇒导致Q值的过高估计 且误差逐步累积.

- 真实值.
- 神经网络估计偏差.
- 行动后价值变化.

于是 Double DQN 提出使用2个独立神经网络估算 $\max_{a'} Q^*(s', a')$

即：$Q_{w^-}(s', \arg\max_{a'} Q_w(s', a'))$

用 Q_w 输出选择价值最大的动作，用 Q_{w^-} 估算该动作价值.

流程：1. Q_w 选择在 Q_w 中价值最大的动作.

2. 用 Q_{w^-} 估算动作价值更新 Q_w.
3. k步迭代后同步给 Q_{w^-}

⟶ 实验结果表 DQN 则为较少出现Q值大于0的情况.

Dueling DQN

优势函数 $A(s,a) = Q(s,a) - V(s)$.

Dueling DQN 中 Q 网络建模为：

$$Q_{\eta,\alpha,\beta}(s,a) = V_{\eta,\alpha}(s) + A_{\eta,\beta}(s,a)$$

训练神经网络最后几层的2个分支分别输出 $V(s)$ 和 $A(s,a)$，最后求和得 $Q(s,a)$

夸克扫描王 极速扫描，就是高效

RL-14

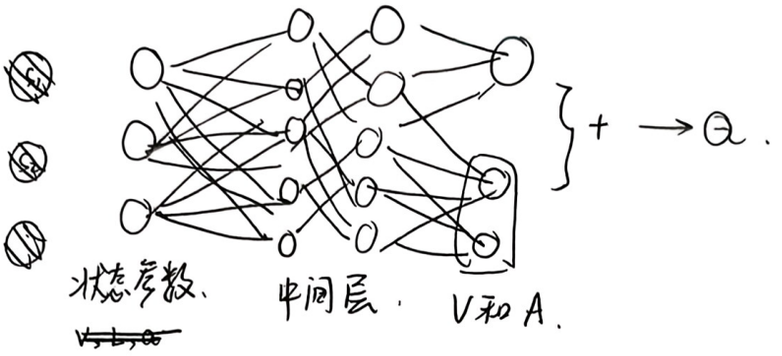

防止智能体只关注状态价值而不关注不同动作导致的差异.

∵ $(V(s)+C)+(A(s,a)-C) = V(s)+A(s,a)$.

∴ 为防止建模不唯一导致的不稳定，令 最优动作的优势函数实际输出0.

即: $Q_{\eta,\alpha,\beta}(s,a) = V_{\eta,\alpha}(s) + A_{\eta,\beta}(s,a) - \max_{a'} A_{\eta,\beta}(s,a')$.

此时 $V(s) = \max_a Q(s,a)$

实现时也可用平均代替最大化.

$$Q_{\eta,\alpha,\beta}(s,a) = V_{\eta,\alpha}(s) + A_{\eta,\beta}(s,a) - \frac{1}{|A|}\sum_{a'} A_{\eta,\beta}(s,a')$$

第九章. 策略梯度算法.

- 基于价值：根据价值选择策略，学习过程并无一个显式策略
- 基于策略：直接学习一个显式的策略

假设 π_θ 为一随机性策略，且处处可微. 目标函数为:

$$J(\theta) = E_{s_0}[V^{\pi_\theta}(s_0)]$$

其中 s_0 为初始状态. 对 $J(\theta)$ 求导，策略 π 下的状态访问分布用 ν^π 表示.

$$\nabla_\theta J_{\pi_\theta}(\theta) \propto \sum_{s\in S} \nu^{\pi_\theta}(s) \sum_{a\in A} Q^{\pi_\theta}(s,a) \nabla_\theta \pi_\theta(a|s)$$

(证明于 RL-15)

夸克扫描王
极速扫描，就是高效

RL-15

证明：从状态价值函数开始。

$$\nabla_\theta V^{\pi_\theta}(s) = \nabla_\theta \left(\sum_{a\in A} \pi_\theta(a|s) Q^{\pi_\theta}(s,a) \right)$$

$$= \sum_{a\in A} \left(\nabla_\theta \pi_\theta(a|s) Q^{\pi_\theta}(s,a) + \pi_\theta(a|s) \nabla_\theta Q^{\pi_\theta}(s,a) \right)$$

$$= \sum_{a\in A} \Big(\cdots \quad \cdots + \pi_\theta(a|s) \nabla_\theta \sum_{s',r} p(s',r|s,a)(r + \gamma V^{\pi_\theta}(s')) \Big)$$

去除不相干的变量。

$$= \sum_{a\in A} (\cdots \quad \cdots + \gamma \pi_\theta(a|s) \sum_{s'} p(s'|s,a) \nabla_\theta V^{\pi_\theta}(s'))$$

为简化表示，令 $\phi(s) = \sum_{a\in A} \nabla_\theta \pi_\theta(a|s) Q^{\pi_\theta}(s,a)$

定义：$d^{\pi_\theta}(s \to x, k)$ 为策略 π_θ 下，从 s 出发 k 步后到 x 的概率。

$$\nabla_\theta V^{\pi_\theta}(s) = \phi(s) + \gamma \sum_a \pi_\theta(a|s) \sum_{s'} p(s'|s,a) \nabla_\theta V^{\pi_\theta}(s')$$

$$= \phi(s) + \gamma \sum_a \sum_{s'} \pi_\theta(a|s) p(s'|s,a) \nabla_\theta V^{\pi_\theta}(s')$$

$$= \phi(s) + \gamma \sum_{s'} d^{\pi_\theta}(s \to s', 1) \nabla_\theta V^{\pi_\theta}(s')$$

$$= \phi(s) + \gamma \sum_{s'} d^{\pi_\theta}(s \to s', 1) \left[\phi(s') + \gamma \sum_{s''} d^{\pi_\theta}(s' \to s'', 1) \nabla_\theta V^{\pi_\theta}(s'') \right]$$

$$= \cdots$$

$$= \sum_{x\in S} \sum_{k=0}^{\infty} \gamma^k d^{\pi_\theta}(s \to x, k) \phi(x)$$

定义 $\eta(s) = E_{s_0}\left[\sum_{k=0}^{\infty} \gamma^k d^{\pi_\theta}(s_0 \to s, k) \right]$

回到目标函数：$\nabla_\theta J(\theta) = \nabla_\theta E_{s_0}[V^{\pi_\theta}(s_0)]$

$$= \sum_s E_{s_0}\left[\sum_{k=0}^{\infty} \gamma^k d^{\pi_\theta}(s_0 \to s, k) \right] \phi(s).$$

$$= \sum_s \eta(s) \phi(s)$$

$$= \left(\sum_s \eta(s) \right) \cdot \sum_s \frac{\eta(s)}{\sum_s \eta(s)} \phi(s)$$

$$\propto \sum_s \frac{\eta(s)}{\sum_s \eta(s)} \phi(s) = \sum_s \nu^{\pi_\theta}(s) \sum_a Q^{\pi_\theta}(s,a) \nabla_\theta \pi_\theta(a|s)$$

夸克扫描王
极速扫描，就是高效

RL-16

$$\nabla_\theta J(\theta) \propto \sum_{s\in S} \nu^{\pi_\theta}(s) \sum_{a\in A} Q^{\pi_\theta}(s,a) \nabla_\theta \pi_\theta(a|s)$$

$$= \sum_{s\in S} \nu^{\pi_\theta}(s) \sum_{a\in A} \pi_\theta(a|s) Q^{\pi_\theta}(s,a) \frac{\nabla_\theta \pi_\theta(a|s)}{\pi_\theta(a|s)}$$

$$= E_{\pi_\theta}[Q^{\pi_\theta}(s,a) \nabla_\theta \log \pi_\theta(a|s)]$$

可用此梯度来更新策略，须使用当前策略π_θ采样得到的数据来计算梯度。直观理解公式即更多采样Q值大的动作。

对于用到的$Q^{\pi_\theta}(s,a)$，有多种估计方法，

Reinforce算法是用蒙特卡洛方法进行估计

对有限步数环境更新策略为：

$$\nabla_\theta J(\theta) = E_{\pi_\theta}\left[\sum_{t=0}^{T} \left(\sum_{t'=t}^{T} \gamma^{t'-t} r_{t'}\right) \nabla_\theta \log \pi_\theta(a_t|s_t)\right]$$

Actor-Critic

拟合一个值函数来指导策略学习。

在策略梯度中，梯度可写为以下更一般的形式：

$$g = E\left[\sum_{t=0}^{T} \psi_t \nabla_\theta \log \pi_\theta(a_t|s_t)\right].$$

其中π_θ可有多种形式：

1. $\sum_{t=0}^{T} \gamma^{t'} r_{t'}$：轨迹总回报
2. $\sum_{t=t}^{T} \gamma^{t'-t} r_{t'}$：动作$a_t$之后的回报。
3. $\sum_{t=t}^{T} \gamma^{t'-t} r_{t'} - b(s_t)$：基准线版本的改进。
4. $Q^{\pi_\theta}(s_t, a_t)$。
5. $A^{\pi_\theta}(s_t, a_t) = Q^{\pi_\theta}(s_t, a_t) - V^{\pi_\theta}(s_t)$
6. $r_t + \gamma V^{\pi_\theta}(s_{t+1}) - V^{\pi_\theta}(s_t)$：时序差分残差。

夸克扫描王
极速扫描，就是高效

RL-17.

用(3)的基线函数来减小方差，原理等效于多步Sarsa算法.

用(4)即为用AC方法得到的Q代替

用(6)即为 $Q = r + \gamma V$

此处着重介绍(6)：

①. Critic 价值网络表示为 V_w，参数为 w，其损失函数为：

$$\mathcal{L}(w) = \frac{1}{2}(r + \gamma V_w(s_{t+1}) - V_w(s_t))^2$$

冻结参数视为常数不参与求导.

$$\nabla_w \mathcal{L}(w) = -(r + \gamma V_w(s_{t+1}) - V_w(s_t)) \nabla_w V_w(s_t).$$

用梯度下降更新 Critic 参数.

②. Actor 用策略梯度规则.

③. 流程：初始化网络参数 θ. w.

(策) (价).

(A) (C).

for 序列 $e = 1 \to E$, do:

用策略 π_θ 采样 $*$ 轨迹 $\{s_1, a_1, r_1, s_2, a_2, r_2, \dots\}$

给每一步数据计算 $\delta_t = r_t + \gamma V_w(s_{t+1}) - V_w(s_t)$.

更新价值参数 $w = w + \alpha_w \sum_t \delta_t \nabla_w V_w(s_t)$. (critic)

更新策略参数 $\theta = \theta + \alpha_\theta \sum_t \delta_t \nabla_\theta \log \pi_\theta(a_t | s_t)$ (actor)

end for

TRPO

$$J(\theta) = E_{s_0}[V^{\pi_\theta}(s_0)] = E_{\pi_\theta}[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)]$$

策略目标为找到 $\theta^* = \arg\max_\theta J(\theta)$

但可能因步长过长策略突然显著变差，影响训练效果.

→ 找到信任区域，在其上有安全性保证，信任区域策略优化 (TRPO)

夸克扫描王
极速扫描，就是高效

RL-18

11.2 策略目标

策略 π_θ，参数 θ，考虑如何借助当前 θ 找到更优参数 θ'，s.t. $J(\theta') > J(\theta)$.

$$J(\theta) = E_{s_0}[V^{\pi_\theta}(s_0)]$$

$$= E_{\pi_{\theta'}}\left[\sum_{t=0}^{\infty}\gamma^t V^{\pi_\theta}(s_t) - \sum_{t=1}^{\infty}\gamma^t V^{\pi_\theta}(s_t)\right] \quad \text{(由于初始状态与策略无关)}$$

$$= -E_{\pi_{\theta'}}\left\{\sum_{t=0}^{\infty}\gamma^t\left[\gamma V^{\pi_\theta}(s_{t+1}) - V^{\pi_\theta}(s_t)\right]\right\}$$

基于以上连接推导：

$$J(\theta') - J(\theta) = E_{s_0}[V^{\pi_{\theta'}}(s_0)] - E_{s_0}[V^{\pi_\theta}(s_0)]$$

$$= E_{\pi_{\theta'}}\left[\sum_{t=0}^{\infty}\gamma^t r(s_t,a_t)\right] + E_{\pi_{\theta'}}\left\{\sum_{t=0}^{\infty}\gamma^t\left[\gamma V^{\pi_\theta}(s_{t+1}) - V^{\pi_\theta}(s_t)\right]\right\}$$

$$= E_{\pi_{\theta'}}\left\{\sum_{t=0}^{\infty}\gamma^t\left[\underbrace{r(s_t,a_t) + \gamma V^{\pi_\theta}(s_{t+1}) - V^{\pi_\theta}(s_t)}_{\text{定义为 } A^{\pi_\theta}(s_t,a_t)}\right]\right\}$$

$$= E_{\pi_{\theta'}}\left[\sum_{t=0}^{\infty}\gamma^t A^{\pi_\theta}(s_t,a_t)\right]$$

$$= \sum_{t=0}^{\infty}\gamma^t E_{s_t\sim P_t^{\pi_{\theta'}}} E_{a_t\sim\pi_{\theta'}(\cdot|s)}[A^{\pi_\theta}(s_t,a_t)]$$

$$= \frac{1}{1-\gamma} E_{s\sim\nu^{\pi_{\theta'}}} E_{a\sim\pi_{\theta'}(\cdot|s)}[A^{\pi_\theta}(s,a)]$$

利用状态访问分布定义：$\nu^\pi(s) = (1-\gamma)\sum_{t=0}^{\infty}\gamma^t P_t^\pi(s)$

只需要 $J(\theta') - J(\theta) \geq 0$ 即保证策略性能↑，但直接求解不现实，因不同数据要拿来收集样本判断哪个得合并不可能.

因此，TRPO 忽略状态访问分布变化，用 π_θ 的状态分布

即定义：

$$L_\theta(\theta') = J(\theta) + \frac{1}{1-\gamma} E_{s\sim\nu^{\pi_\theta}} E_{a\sim\pi_{\theta'}(\cdot|s)}[A^{\pi_\theta}(s,a)]$$

当新旧策略十分接近，状态访问分布变化较小，动作仍用新策略 $\pi_{\theta'}$ 采样得到. 用重要性采样对动作分布进行处理：

$$L_\theta(\theta') = J(\theta) + E_{s\sim\nu^{\pi_\theta}} E_{a\sim\pi_\theta(\cdot|s)}\left[\frac{\pi_{\theta'}(a|s)}{\pi_\theta(a|s)} A^{\pi_\theta}(s,a)\right]$$

于是可用旧策略数据估计并优化新策略.

夸克扫描王
极速扫描，就是高效

RL-19.

为保证新旧策略足够接近，使用KL散度来衡量策略之间的距离

$$\max_{\theta'} L_\theta(\theta')$$
$$s.t.\ E_{s\sim\nu^{\pi_\theta}}[D_{KL}(\pi_{\theta_k}(\cdot|s), \pi_{\theta'}(\cdot|s))] \le \delta$$

此处不等式约束定义了一个KL球，被称为信任区域，该区域中可认为 $E_{s\sim\nu^{\pi_\theta}} \approx E_{s\sim\nu^{\pi_{\theta'}}}$，进而可基于重要性采样实现策略提升.

D_{KL} 注：离散动作空间中 $D_{KL}(P,Q) = \sum_a P(a) \log \frac{P(a)}{Q(a)}$.

关键性质：1.非负性 $D_{KL} \ge 0$.

当且仅当 $P=Q$ 时，$KL=0$；差距个数值个.

2. 不对称 $D_{KL}(P,Q) \neq D_{KL}(Q,P)$

$D_{KL}(P,Q)$ 是以 P 为基准，衡量 Q 有多偏离 P

TRPO中固定写法：$D_{KL}(\pi_{old}, \pi_{new})$.

3. 不是距离衡量.

不满足三角不等式，不可当作欧式距离，只能衡量分布差异.

11.3 近似求解.

直接求解带约束的优化问题比较麻烦，用近似求解：对目标函数和约束在 θ_k 进行泰勒展开，用1阶、2阶近似：

$$E_{s\sim\nu^{\pi_\theta}} E_{a\sim\pi_\theta(\cdot|s)}\left[\frac{\pi_{\theta'}(a|s)}{\pi_\theta(a|s)} A^{\pi_\theta}(s,a)\right] \approx g^T(\theta'-\theta_k).$$

$$E_{s\sim\nu^{\pi_{\theta_k}}}[D_{KL}(\pi_{\theta_k}(\cdot|s), \pi_{\theta'}(\cdot|s))] \approx \frac{1}{2}(\theta'-\theta_k)^T H (\theta'-\theta_k).$$

其中 $g = \nabla_{\theta'} \boxed{E_{s\sim\nu^{\pi_{\theta_k}}} E_{a\sim\pi_{\theta_k}(\cdot|s)}\left[\frac{\pi_{\theta'}(a|s)}{\pi_{\theta_k}(a|s)} A^{\pi_{\theta_k}}(s,a)\right]}$ 表示目标函数梯度

$H = H\left[E_{s\sim\nu^{\pi_{\theta_k}}}[D_{KL}(\pi_{\theta_k}(\cdot|s), \pi_{\theta'}(\cdot|s))]\right]$ 表示策略之间平均KL距离的Hessian矩阵.

优化目标变成了：

$$\theta_{k+1} = \arg\max_{\theta'} g^T(\theta'-\theta_k)$$
$$s.t.\ \frac{1}{2}(\theta'-\theta_k)^T H (\theta'-\theta_k) \le \delta$$

夸克扫描王 极速扫描，就是高效

RL-20

注：之所以用H的2阶近似，用简单理解可以为：只有到2阶才非0，因 $D_{KL} \geq 0$，而若 D_{KL} 的一阶导非0，则一定存在一个方向增一个方向减，这种线性违背了~~大于等于0~~的 $D_{KL} \geq 0$。（直观上理解）

对以上问题，使用KKT条件求解

$$\theta_{k+1} = \theta_k + \sqrt{\frac{2\delta}{g^T H^{-1} g}} H^{-1} g.$$

补：KKT条件.

$$\begin{cases} \min\limits_x f(x) \\ \text{s.t. } h_i(x) = 0 \quad i = 1, \cdots, m \\ \quad g_j(x) \leq 0 \quad j = 1, \cdots, l \end{cases}$$

$L = f(x) + \sum_i \lambda_i h_i(x) + \sum_j \mu_j g_j(x)$ 其中 $\mu_j \geq 0$，不等式约束对应乘子非负

1. $\nabla L(x^*) = 0$
2. $h_i(x^*) = 0$，$g_j(x^*) \leq 0$.
3. $\mu_j \geq 0$.
4. $\mu_j g_j(x^*) = 0$ 互补松弛条件.
   - $g_j(x^*) < 0$ 内部点 $\rightarrow \mu_j = 0$ 退化为无约束优化.
   - $g_j(x^*) = 0$ 边界 $\rightarrow \mu_j \geq 0$ 约束限制.

对 $\begin{cases} \theta_{k+1} = \arg\max\limits_{\theta'} g^T(\theta' - \theta_k) \\ \text{s.t. } \frac{1}{2}(\theta' - \theta_k)^T H (\theta' - \theta_k) \leq \delta \end{cases}$ 求解：$\begin{cases} f(\Delta\theta) = -g^T \Delta\theta \\ g(\Delta\theta) = \frac{1}{2}\Delta\theta^T H \Delta\theta - \delta \end{cases}$

$L = -g^T \Delta\theta + \mu(\frac{1}{2}\Delta\theta^T H \Delta\theta - \delta)$，$\mu \geq 0$

1. ~~$\nabla_{\Delta\theta} L(\Delta\theta)$~~ $\nabla_{\Delta\theta} L = 0$.

   $\therefore -g^T + \mu H \Delta\theta = 0$ (1)
2. $\frac{1}{2}\Delta\theta^T H \Delta\theta - \delta \leq 0$.
3. $\mu \geq 0$.
4. $\mu(\frac{1}{2}\Delta\theta^T H \Delta\theta - \delta) = 0$

由(1)：假定H可逆，$\Delta\theta = \mu^{-1} H^{-1} g$

令 $x = H^{-1} g$，$\Delta\theta = \alpha x$，$\alpha = \frac{1}{\mu}$

∵最优点在边界上

$\therefore \frac{1}{2}\Delta\theta^T H \Delta\theta - \delta = 0$.

即 $\frac{1}{2}\alpha^2 \cdot x^T H x = \delta$

$\frac{1}{2}\alpha^2 \cdot g^T H^{-1} H H^{-1} g = \delta$.

$\therefore \alpha = \sqrt{\frac{2\delta}{g^T H^{-1} g}}$

$\therefore \Delta\theta = \sqrt{\frac{2\delta}{g^T H^{-1} g}} \cdot H^{-1} g$

夸克扫描王 极速扫描，就是高效

RL-21.

11.4 共轭梯度 (未看懂)

由于用神经网络表示的策略函数的参数数量成千上万，计算存储 Hessian 矩阵耗大量内存资源和时间。

TRPO 用共轭梯度法规避这一问题，思想即直接计算 $x = H^{-1}g$，x 即参数更新方向。假设满足 KL 距离约束的参数更新最大步长为 β，于是根据 KL 距离约束条件有：$\frac{1}{2}(\beta x)^T H (\beta x) = \delta$

求解：$\beta = \sqrt{\frac{2\delta}{x^T H x}}$

$\therefore \theta_{k+1} = \theta_k + \sqrt{\frac{2\delta}{x^T H x}} x$

因此可直接用 x 来更新参数。问题即转化为解 $Hx = g$

而 H 为对称正定矩阵，故可用共轭梯度法求解

流程如下：初始化 $r_0 = g - Hx_0$，$p_0 = r_0$，$x_0 = 0$

for $k = 0 \to N$ do:

$$\alpha_k = \frac{r_k^T r_k}{p_k^T H p_k}$$

$$x_{k+1} = x_k + \alpha_k p_k$$

$$r_{k+1} = r_k - \alpha_k H p_k$$

若 $r_{k+1}^T r_{k+1}$ 非常小，则退出循环.

$$\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$$

$$p_{k+1} = r_{k+1} + \beta_k p_k$$

end for.

输出 x_{N+1}

$$Hv = \nabla_\theta\left(\left(\nabla_\theta\left(D_{KL}^{\pi_{\theta_k}}(\pi_{\theta_k}, \pi_{\theta'})\right)\right)^T\right)v = \nabla_\theta\left(\left(\nabla_\theta\left(D_{KL}^{\pi_{\theta_k}}(\pi_{\theta_k}, \pi_{\theta'})\right)\right)^T v\right)$$

夸克扫描王 极速扫描，就是高效

11.5 线性搜索

由于TRPO用了泰勒近似，并非精准求解，因此θ'可能未必有θ_k好，或未必满足KL散度限制。于是TRPO在每次迭代最后进行一次线性搜索。具体来说，就是找到一个最小非负整数i，

不打破KL约束前提下走最K-步，最大化策略改进

$$\text{s.t. 按照 } \theta_{k+1} = \theta_k + \alpha^i \sqrt{\frac{2\delta}{x^T H x}} x$$

求出的θ_{k+1}仅满足最初的KL散度限制，且确能提升目标函数L_{θ_k}。其中$\alpha \in (0,1)$是决定线性搜索长度的超参数。

TRPO算法流程：

初始化策略网络参数θ，价值网络参数w

for 序列 $e: 1 \to E$ do:

(1) 用当前策略π_θ采样轨迹$\{s_1, a_1, r_1, s_2, a_2, r_2 \cdots\}$

(2) 根据采集数据和价值网络估计每个动作对优势$A(s_t,a_t)$

(3) 计算策略目标函数梯度g

(4) 共轭梯度法计算$x = H^{-1}g$

(5) 用线性搜索找到一个i，更新$\theta_{k+1} = \theta_k + \alpha^i \sqrt{\frac{2\delta}{x^T H x}} x$，其中$i \in \{1,2 \cdots K\}$为能提升策略并满足KL距离限制的最小整数。

(6) 更新价值网络参数

end for.

11.6 广义优势估计

11.5中提到对策略π_θ如何估计优势，比较常用广义优势估计（GAE）

用$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$表示时序差分误差，其中$V$是已经学习的状态价值函数。

于是有：

$$A_t^{(1)} = \delta_t = -V(s_t) + r_t + \gamma V(s_{t+1})$$

$$A_t^{(2)} = \delta_t + \gamma\delta_{t+1} = -V(s_t) + r_t + \gamma r_{t+1} + \gamma^2 V(s_{t+2})$$

$$A_t^{(3)} = \delta_t + \gamma\delta_{t+1} + \gamma^2\delta_{t+2} = -V(s_t) + r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \gamma^3 V(s_{t+3})$$

$$A_t^{(k)} = \sum_{l=0}^{k-1} \gamma^l \delta_{t+l} = -V(s_t) + r_t + \cdots + \gamma^{k-1} r_{t+k-1} + \gamma^k V(s_{t+k})$$

夸克扫描王 极速扫描，就是高效

RL-23

GAE将不同步数的优势指数加权平均.

$$A_t^{GAE} = (1-\lambda)\left(A_t^{(1)} + \lambda A_t^{(2)} + \lambda^2 A_t^{(3)} + \cdots\right)$$

$$= (1-\lambda)\left[\delta_t + \lambda(\delta_t + \gamma\delta_{t+1}) + \lambda^2(\delta_t + \gamma\delta_{t+1} + \gamma^2\delta_{t+2}) + \cdots\right]$$

$$= (1-\lambda)\left[\delta_t(1+\lambda+\lambda^2+\cdots) + \gamma\delta_{t+1}(\lambda+\lambda^2+\cdots) + \cdots\right]$$

$$= (1-\lambda)\left(\delta_t \frac{1}{1-\lambda} + \gamma\delta_{t+1}\frac{\lambda}{1-\lambda} + \cdots\right)$$

$$= \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}$$

其中 $\lambda \in [0,1]$ 是GAE中引入额外的超参数.

$\begin{cases} \lambda=0: A_t^{GAE} = \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t) & \text{仅看一步差分} \\ \lambda=1: A_t^{GAE} = \sum_{l=0}^{\infty}\gamma^l\delta_{t+l} = \sum_{l=0}^{\infty}\gamma^l r_{t+l} - V(s_t) & \text{看每一步差分得到优势时完全平均} \end{cases}$

第12章 PPO算法.

相比TRPO, PPO的速度更快,更简单,效果一样好.

回忆TRPO的优化目标 $\max_\theta E_{s\sim\nu^{\pi_{\theta_k}}} E_{a\sim\pi_{\theta_k}(\cdot|s)}\left[\frac{\pi_\theta(a|s)}{\pi_{\theta_k}(a|s)} A^{\pi_{\theta_k}}(s,a)\right]$

$$\text{s.t. } E_{s\sim\nu^{\pi_{\theta_k}}}\left[D_{KL}(\pi_{\theta_k}(\cdot|s), \pi_\theta(\cdot|s))\right] \le \delta.$$

TRPO求解: 泰勒展开近似. 共轭梯度. 线性搜索.

PPO求解 < PPO惩罚
PPO截断

12.2 PPO-惩罚.

用拉格朗日乘子法:

$$\arg\max_\theta E_{s\sim\nu^{\pi_{\theta_k}}} E_{a\sim\pi_{\theta_k}(\cdot|s)}\left[\frac{\pi(a|s)}{\pi_{\theta_k}(a|s)} A^{\pi_{\theta_k}}(s,a) - \beta D_{KL}[\pi_{\theta_k}(\cdot|s), \pi_\theta(\cdot|s)]\right]$$

令 $d_k = D_{KL}^{\nu^{\pi_{\theta_k}}}(\pi_{\theta_k}, \pi_\theta)$, β 更新规则如下:

1. 若 $d_k < \frac{\delta}{1.5}$ 则 $\beta_{k+1} = \frac{\beta_k}{2}$
2. 若 $d_k > 1.5\delta$ 则 $\beta_{k+1} = 2\beta_k$
3. 否则 $\beta_{k+1} = \beta_k$

夸克扫描王
极速扫描，就是高效

RL—24

12.3 PPO—截断.（PPO-Clip）（相较PPO-惩罚效果更好）.

更加直接，在目标函数中进行限制，以保证新旧参数差距不太大.

$$\arg\max_\theta E_{s\sim\nu^{\pi_{\theta_k}}} E_{a\sim\pi_{\theta_k}(\cdot|s)}\left[\min\left(\frac{\pi_\theta(a|s)}{\pi_{\theta_k}(a|s)}A^{\pi_{\theta_k}}(s,a),\ \mathrm{clip}\left(\frac{\pi_\theta(a|s)}{\pi_{\theta_k}(a|s)},1-\epsilon,1+\epsilon\right)A^{\pi_{\theta_k}}(s,a)\right)\right]$$

其中 $\mathrm{clip}(x,l,r):=\max(\min(x,r),l)$ 即把 x 限制在 $[l,r]$ 内，上式中 ϵ 是一个超参数表示进行截断（clip）的范围。

若 $A^{\pi_{\theta_k}}(s,a)>0$ 说明该动作高于平均，最大化该式会增大 $\frac{\pi_\theta(a|s)}{\pi_{\theta_k}(a|s)}$.
但不会让其超过 $1+\epsilon$.

反之若 $A^{\pi_{\theta_k}}(s,a)<0$ 最大化这个式子会减小 $\frac{\pi_\theta(a|s)}{\pi_{\theta_k}(a|s)}$，但不会使其超过 $1-\epsilon$

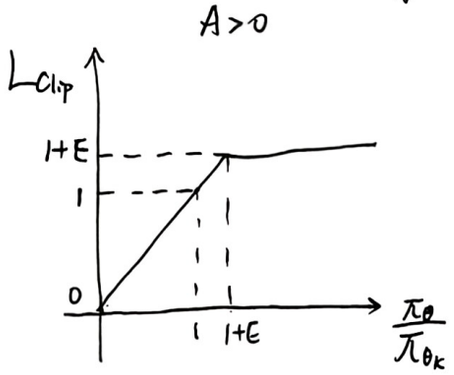

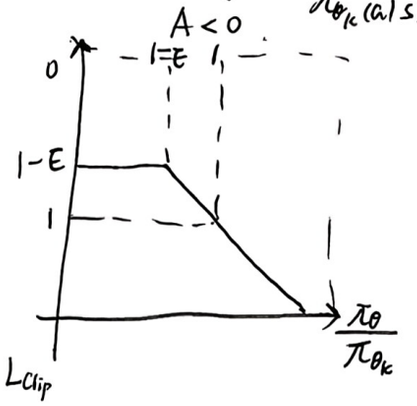

第13章 DDPG算法.

TRPO和PPO因都是在线策略算法，意味着其样本效率比较低.
DQN直接估计最优函数Q，可做到离线策略学习，但只能处理动作空间有限的环境

考虑使用类似思想处理动作空间无限且离线策略学习的算法

→ ~~深度策略性梯度~~ 深度确定性策略梯度（DDPG）.

构造确定性策略用梯度上升无法最大化Q值，DDPG也属于一种A-C算法，
Reinforce、TRPO、PPO学习随机性策略，DDPG学习确定性策略

确定性 $a=\mu_\theta(s)$
随机性 $a\sim\pi_\theta(\cdot|s)$

确定性策略梯度定理：

$$\nabla_\theta J(\pi_\theta)=E_{s\sim\nu^\pi}\left[\nabla_\theta\mu_\theta(s)\nabla_a Q_w^\mu(s,a)\big|_{a=\mu_\theta(s)}\right]$$

夸克扫描王 极速扫描，就是高效

RL——25.

π_β 是用来收集数据的行为策略.

无法遍历所有动作来得到Q值最大的动作，因此想用策略 μ 找到使 $Q(s,a)$ 值最大的动作 a，即 $\mu(s) = \arg\max_a Q(s,a)$.

Q是Critic，μ 是Actor.

对于如何得到 μ，用Q对 μ_θ 求导 $\nabla_\theta Q(s, \mu_\theta(s))$，会用到链式法则，先对 a 求导再对 θ 求导，再用梯度上升最大化Q

Actor和Critic各使用2个神经网络，原因见DQN.

DDPG中目标网络更新与DQN中略不同，

- DQN：过段时间将参数复制给目标网络.
- DDPG：软更新，让目标网络缓慢更新.

$$w^- \leftarrow \tau w + (1-\tau) w^-$$ （通常 τ 为比较小的数）

对于Q估计过高问题，DDPG依照Double DQN更新网络.

+ DDPG在行为策略引入噪声N，用随机网络参数 w 和 θ 分别初始化Critic网络和Actor网络，复制相同参数 $w^- \leftarrow w$，$\theta^- \leftarrow \theta$，分别初始化 $Q_w(s,a)$ $\mu_\theta(s)$ Q_{w^-} 和 μ_{θ^-} 初始化经验回放池 R
+ for 序列 $e = 1 \to E$ do:
  + 初始化随机过程 $\mathcal{N}$ 用于动作探索
  + 获取环境初始态 s_1
  + ~~for 时间步 $t = 1 \to T$ do:~~
  + ~~根据当前~~
  + for 时间步 $t = 1 \to T$ do:
    + 根据当前策略和噪声选择动作 $a_t = \mu_\theta(s_t) + \mathcal{N}$
    + 执行动作 a_t 获得奖励 r_t，环境状态变为 s_{t+1}
    + 将 (s_t, a_t, r_t, s_{t+1}) 存储放进回放池 R.
    + 从R中采样N个元组 $\{(s_i, a_i, r_i, s_{i+1})\}_{i=1,\dots,N}$
    + 对每个元组计算 $y_i = r_i + \gamma Q_{w^-}(s_{i+1}, \mu_{\theta^-}(s_{i+1}))$
    + 最小化 $L = \frac{1}{N}\sum_{i=1}^{N}(y_i - Q_w(s_i, a_i))^2$，以此更新Critic网络.
    + 计算采样的策略梯度，以此更新Actor网络：

$$\nabla_\theta J \approx \frac{1}{N}\sum_{i=1}^{N} \nabla_\theta \mu_\theta(s_i) \nabla_a Q_w(s_i, a)\big|_{a=\mu_\theta(s_i)}$$

夸克扫描王 极速扫描，就是高效

RL-2k + 更新目标网络：

$w^- \leftarrow \tau w + (1-\tau) w^-$ 软更新 | $\theta^- \leftarrow \tau\theta + (1-\tau)\theta^-$ 软更新

+ end for

+ endfor

第14章 SAC算法 (Soft-Actor-Critic)

- 虽DDPG是离线策略算法，但训练不稳定收敛性较差，对超参数敏感，难以适配复杂环境，因此提出SAC（更稳定）。
- SAC前身为 Soft Q-Learning，属最大熵强化学习的范围
- Soft-Q-Learning 不存在一个显式策略函数，而是使用一个函数Q的波尔兹曼分布 在连续空间求解很麻烦，于是 SAC 提出使用一个 Actor表示策略函数 从而解决。
- 目前在无模型强化学习中，SAC是一个非常高效的算法，它学习了随机性策略，取得了领先的成绩

14.2 最大熵强化学习

设 x 为随机变量，概率密度函数为 p，熵 H：

$$H(x) = E_{x\sim p}[-\log p(x)]$$

用 $H(\pi(\cdot|s))$ 表示策略 π 在 s 下的随机程度

最大熵强化学习思想：最优累积奖励且策略更加随机，为此加入正则项：

$$\pi^* = \arg\max_\pi E_\pi\left[\sum_t r(s_t,a_t) + \alpha H(\pi(\cdot|s_t))\right]$$

其中 α 是正则化系数，用来控制熵的重要程度

α 越大探索性越强 → 可改为自适应，先大量探索加速再减少

14.3. Soft 策略迭代

soft 贝尔曼方程：

$$Q(s_t,a_t) = r(s_t,a_t) + \gamma E_{s_{t+1}}[V(s_{t+1})]$$

其中，

$$V(s_t) = E_{a_t\sim\pi}[Q(s_t,a_t) - \alpha\log\pi(a_t|s_t)] = E_{a_t\sim\pi}[Q(s_t,a_t)] + H(\pi(\cdot|s_t))$$

夸克扫描王 极速扫描，就是高效

于是，根据 Soft 贝尔曼方程，在有限的状态和动作空间情况下，Soft 策略评估可以收敛到策略 π 的 Soft Q 函数，根据 Soft 策略提升公式可改进策略：

$$\pi_{new} = \arg\min_{\pi'} D_{KL}\left(\pi'(\cdot|s), \underbrace{\frac{\exp(\frac{1}{\alpha}Q^{\pi_{old}}(s,\cdot))}{Z^{\pi_{old}}(s,\cdot)}}_{\text{波尔兹曼分布}}\right)$$

但仅适用于有限状态、动作空间，在连续空间下，我们通过参数化函数 Q 策略 π 来近似这样的迭代。

14.4 SAC

在 SAC 算法中，我们分为两个动作价值函数 Q（参数分别为 w_1 和 w_2）和一个策略函数 π（参数为 θ）建模。

基于 Double DQN 的思想，SAC 使用两个 Q 网络，但每次用 Q 网络时会挑选一个 Q 值小的网络，从而缓解 Q 值过高的问题。任意一个 Q 的损失函数为：

$$L_Q(w) = \underbrace{E_{(s_t,a_t,r_t,s_{t+1})\sim R}}_{\downarrow}\left[\frac{1}{2}\left(Q_w(s_t,a_t) - \underbrace{(r_t + \gamma V_{w^-}(s_{t+1}))}_{\downarrow}\right)^2\right]$$

$\downarrow$ $E_{(s_t,a_t,r_t,s_{t+1})\sim R, a_{t+1}\sim\pi_\theta(\cdot|s_{t+1})}$

$\downarrow$ $r_t + \gamma\left(\min_{j=1,2} Q_{w_j^-}(s_{t+1},a_{t+1}) - \alpha\log\pi(a_{t+1}|s_{t+1})\right)$

R 是策略过去收集的数据

SAC 目标网络更新方式与 DDPG 相同。

策略 π 的损失函数根据 $L_\pi(\theta)$（RL-26 见）可理解为最大化 $V(s_t)$。

对连续动作空间环境，SAC 算法的策略输出高斯分布的均值，但根据高斯分布采样的动作过程不可导，因此使用**重参数化技巧**

△ 重参数化技巧：

先从一个单位高斯分布 N 采样，再把采样值乘标准差后加上均值。

这样可以为是从策略高斯分布采样，这样是可导的

$$a = \mu_\theta(s) + \sigma_\theta(s)\odot\epsilon = f_\theta(\epsilon_t; s_t)$$ 其中 ϵ_t 是一个噪声随机变量

$$\therefore L_\pi(\theta) = E_{s_t\sim R,\epsilon_t\sim N}\left[\alpha\log(\pi_\theta(f_\theta(\epsilon_t;s_t)|s_t)) - \min_{j=1,2} Q_{w_j}(s_t, f_\theta(\epsilon_t;s_t))\right]$$

夸克扫描王 极速扫描，就是高效

RL-28

自动调整熵正则项

于是改为带约束的优化问题：

$$\max_{\pi} E_{\pi}\left[\sum_t r(s_t,a_t)\right] \quad \text{s.t. } E_{(s_t,a_t)\sim\rho_\pi}\left[-\log(\pi_t(a_t|s_t))\right] \geq H_0$$

最大化期望回报，同时约束熵均值大于 H_0。

α 的损失函数：$L(\alpha) = E_{s_t\sim R,\, a_t\sim\pi(\cdot|s_t)}\left[-\alpha\log\pi(a_t|s_t) - \alpha H_0\right]$

当策略熵低于 H_0 时，训练目标 $L(\alpha)$ 会使 α 值增大
～～ 高于 ～～，～～～～～～ ～～ 减小，更注重价值提升。

SAC 共使用 5 个网络：策略网络 ×1，利用 Double DQN 思想的 2 个 Q 网络，及其配套的 2 个目标网络。

第 15 章 模仿学习

- 行为克隆 (BC)
- 逆强化学习 (inverse RL) 计算复杂度高，实际应用价值小
- 生成式对抗模仿学习 (GAIL)

15.2 行为克隆 (BC)

监督学习方法，将 (s_t, a_t) 的 s_t 看作样本输入，a_t 看作标签。学习目标为：（专家数据）

$$\theta^* = \arg\min_\theta E_{(s,a)\sim B}\left[\mathcal{L}(\pi_\theta(s), a)\right]$$

其中 B 为专家数据集，$\mathcal{L}$ 是对应框架下的损失函数：
- 离散：最大似然估计得
- 连续：均方误差函数

BC 局限性：数据量小时泛化性能差，序贯决策无法学到最优，只要存在一点偏差，就会使下一状态未见过，被称为行为克隆的复合误差。

15.3 生成式对抗模仿学习 (GAIL)

GAIL 实质上是模仿专家策略的占用度量 $\rho_E(s,a)$，即尽量使得策略在环境中所有状态动作对 (s,a) 和占用度量 $\rho_E(s,a)$ 与专家策略相同。

与 BC 不同，GAIL 为达成目标，需不断与环境交互，收集状态信息并做出动作。

夸克扫描王 极速扫描，就是高效

RL-29.

GAIL
- 生成器：策略 π 生成动作
- 判别器 D：(s,a) 作为输入，输出 0~1 的实数，表明判别器认为 (s,a) 来自智能体而非专家的概率。

判别器 D 损失函数为：

$$\mathcal{L}(\phi) = -E_{\rho_\pi}[\log D_\phi(s,a)] - E_{\rho_{\pi_E}}[\log(1-D_\phi(s,a))]$$

→ 最大化区分两组数据，~~输出 $D_\phi(s,a)$~~

奖励设置为 $r(s,a) = -\log D(s,a)$.

第16章 模型预测控制 (MPC)

并不构成显式策略，只根据环境模型选择当前步要采取的动作

16.2 打靶法

使用 MPC 方法主要在 2 个过程中迭代
- 根据历史数据学习环境模型 $\hat{P}(s,a)$
- 和真实环境交互过程中用环境模型选择动作

目标：$\underset{a_{k:k+H}}{\arg\max} \sum_{t=k}^{k+H} r(s_t, a_t)$ s.t. $s_{t+1} = \hat{P}(s_t, a_t)$

其中 H 为推演长度，$\underset{a_{k:k+H}}{\arg\max}$ 表示从所有动作序列中选择奖励最大的

关键是生成一些候选动作序列，生成过程称为打靶.

16.2.1 随机打靶法

在生成每条序列动作的每一个动作时都是从动作空间随机采样一个动作，最终组成 N 条长度为 H 的动作序列.

16.2.2 交叉熵方法

维护一个带参数的分布，用采样结果更新分布的参数，使得分布中获得高累积奖励的概率更高。

```
for e: 1→E do:
    从分布 P(A) 中选 N 条动作序列 A_1, ... A_N.
    对每条序列用环境模型评估累积奖励.
    根据评估结果保留 M 条优序列 A_i1, ... A_iM.
    用动作序列 A_i1 ... A_iM 更新分布 P(A)
end for
计算所有最优动作序列第一个动作均值，作为此刻动作
```

夸克扫描王 极速扫描，就是高效

RL — 30.

16.3 PETS算法.

带有轨迹采样的概率(PETS, probabilistic ensembles with trajectory sampling).

PETS中采用集成学习方法，即构建多个环境模型，用多个模型进行预测，最后使用CEM进行模型预测控制.

因与智能体交互的环境是动态的，所以拟合他的环境模型也是动态的，区分两种不确定性，偶然不确定性和认知不确定性

系统本身的随机性引起　　数据不足引起.

考虑这2种不确定性，定义环境模型输出为一个高斯分布，用来捕捉偶然不确定性，令环境模型为 $\hat{P}$，参数为 θ，基于当前状态动作对 (s_t, a_t) 下一状态 s_t 的分布可以写为：

$$\hat{P}(s_t, a_t) = \mathcal{N}(\mu_\theta(s_t, a_t), \Sigma_\theta(s_t, a_t))$$

这里采用神经网络构建 μ_θ 和 Σ_θ，神经网络损失函数则为：

$$\mathcal{L}(\theta) = \sum_{n=1}^{N} [\mu_\theta(s_n, a_n) - s_{n+1}]^T \Sigma_\theta^{-1}(s_n, a_n)[\mu_\theta(s_n, a_n) - s_{n+1}] + \log \det \Sigma_\theta(s_n, a_n)$$

(即根据概率模型取对数化简得到)

于是得到由神经网络表示的环境模型，在此基础上，用集成捕捉认知不确定性，即构建B个网络框架一样的神经网络，输入都是状态动作对，输出下一状态高斯分布的均值向量和协方差矩阵。但它们用了不同随机初始化参数，每当训练时，会从真实数据中随机采样训练.（样本利用率高!）

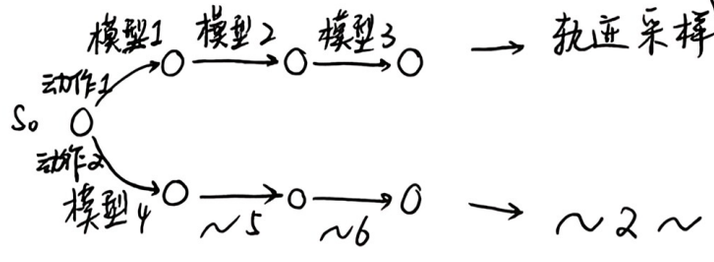

为什么不均值取最多的？计算代价太大？
→会忽略模型之间差异性，且计算时间太长

夸克扫描王
极速扫描，就是高效

RL—31

第17章 基于模型的策略优化.

PETS算法是基于模型的强化学习的一种，没有显式构建一个策略，Dyna-Q算法也是～的～，但Dyna-Q只存储之前遇到的数据，只适用于表格型环境，利用Dyna思想放到PETS中，即在任意动作和状态下用环境模型生成虚拟数据，如此对真实环境样本需求减少，有更高采样效率，即为MBPO算法.

17.2 MBPO算法 (model-based policy optimization, MBPO)

两大问题 (1)随着推演步数变长，模型类计的复合误差会快速增加，
(2)须权衡推演步数增加带来的负面作用和步数增加后策略更优的正面作用

提出分支推演，即模型从之前访问过的状态开始进行较短步数的推演

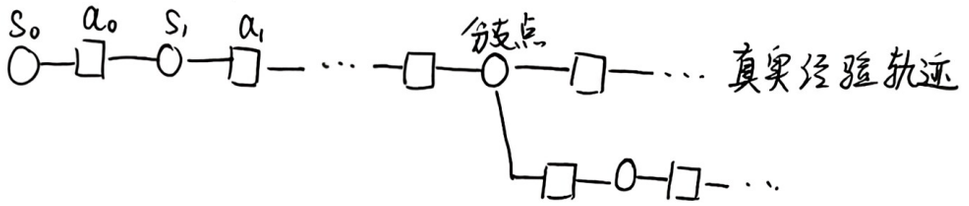

基于环境模型做k步分支推演的轨迹.

①Dyna-Q采用无模型强化学习部分是Q-learning，而MBPO是SAC

②此外，MBPO也是集成学习，每个环境模型输出都是个高斯分布.

初始化策略π_ϕ，环境模型参数P_θ，真实环境数据集D_{env}，模型数据集D_{model}.
for 轮数 $n=1\to N$ do
  通过环境数据训练模型参数P_θ
  for 时间步 $t=1\to T$ do.
    根据策略π_ϕ与环境交互，将轨迹添加到D_{env}中
    for 模型推演次数 $e=1\to E$ do.
      从D_{env}均匀随机采样S_t状态.
      以S_t为初始状态，在模型中使用π_ϕ进行k步推演，生成轨迹添至D_{model}
    end for
    for 策略更新次数 $g=1\to G$ do
      基于D_{model}，用SAC更新策略参数π_ϕ.
    end for
  end for
end for

分支长度k为平衡效率和性能的超参数.

夸克扫描王 极速扫描，就是高效

RL — 32.

第18章 离线强化学习

智能体不和环境交互，仅通过已收集好的确定的数据集获得策略

18.2 批量限制Q-Learning算法 (BCQ)

外推误差是离线策略算法不能直接迁移到离线环境中的原因.

↳指当前策略访问到的状态动作对与从数据集采样得到的状态动作对不匹配而产生的误差

为减少外推误差，当前策略需只访问与数据集中相似的(s,a)数据满足这一要求的数据策略称为批量限制策略.

这样的策略选择动作时有3个目标：

1. 最小化选择的动作与数据集的距离.
2. 采取动作后能到达与离线数据集中状态相似的状态.
3. 最大化函数Q

对标准表格型环境，状态和动作空间有限，标准Q-Learning更新公式为：

$$Q(s,a) \leftarrow (1-\alpha)Q(s,a) + \alpha\left(r + \gamma Q\left(s', \arg\max_{a'} Q(s',a')\right)\right)$$

此时仅需把动作限制在D中，即可满足.

得到表格设定下的批量限制Q-Learning (batch-constrained Q-learning)

$$Q(s,a) \leftarrow (1-\alpha)Q(s,a) + \alpha\left(r + \gamma Q\left(s', \arg\max_{a',\ s.t.(s',a')\in D} Q(s',a')\right)\right)$$

连续状态和动作情况复杂一些，因为批量限制策略的目标需被更详细地定义. eg.如何定义两状态动作对的距离；BCQ采用了一个巧妙方法，训练一个网络&模型$G_w(s)$，对数据集D和其中状态s，$G_w(s)$给出与D中数据最接近的动作$a_1, a_2 \cdots a_n$用于Q网络的训练。为增加生成动作的多样性，减少生成次数，BCQ引入扰动模型$\xi_\phi(s,a,\Phi)$。输入(s,a)时，模型给出一个绝对值最大为Φ的微扰并附加在动作上.综合起来相当于给出一个批量限制策略.

$$\pi(s) = \arg\max_{a_i+\xi_\phi(s,a_i,\Phi)} Q_\theta\left(s, a_i + \xi_\phi(s,a_i,\Phi)\right) \qquad \{a_i \sim G_w(s)\}_{i=1}^n$$

某

夸克扫描王
极速扫描，就是高效

(variation auto-encoder, ~~VAE~~ VAE)

其中生成模型用 $G_w(s)$ 用变分编码器实现；

扰动模型通过确定性策略梯度算法训练，目标是使函数 Q 最大化：

$$\phi \leftarrow \arg\max_{\phi} \sum_{(s,a)\in D} Q_\theta(s, a+\xi_\phi(s,a,\Phi))$$

流程：随机初始化 Q 网络 Q_θ，扰动网络 ξ_ϕ，生成网络 $G_w=\{E_{w_1}, D_{w_2}\}$

用 θ 初始化目标 Q 网络 Q_{θ^-}，用 ϕ 初始化目标扰动网络 ξ_{ϕ^-}

for 训练次数 $e=1\to E$ do

从数据集 D 中采样一定数量 (s,a,r,s')

编码器生成均值和标准差 $\mu,\sigma = E_{w_1}(s,a)$

解码器生成动作 $\tilde{a}=D_{w_2}(s,z)$，其中 $z\sim N(\mu,\sigma)$

更新生成模型 $w \leftarrow \arg\min_w \sum (a-\tilde{a})^2 + D_{KL}(N(\mu,\sigma)\,\|\,N(0,1))$

把隐空间统一规整到 $N(0,1)$.

从生成模型中采样 n 个动作：$\{a_i \sim G_w(s')\}_{i=1}^n$

对每个动作施加微扰动 $\{a_i \leftarrow a_i + \xi_\phi(s', a_i, \phi)\}_{i=1}^n$

计算 Q 网络的目标值：$y = r + \gamma \max_{a_i} Q_{\theta^-}(s', a_i)$

更新 Q 网络：$\theta \leftarrow \arg\min_\theta \sum (y - Q_\theta(s,a))^2$

更新扰动网络：$\phi \leftarrow \arg\max_\phi \sum Q_\theta(s, a+\xi_\phi(s,a,\Phi))$，$a\sim G_w(s)$

更新目标 Q 网络 $\theta^- \leftarrow \tau\theta + (1-\tau)\theta^-$

更新目标扰动网络 $\phi^- \leftarrow \tau\phi + (1-\tau)\phi^-$

endfor

18.3 保守 Q-learning 算法

离线强化学习重点是减小外推误差，实验证明，外推误差主要导致远离数据集的点的 Q 的过高估计，甚至有向上发散。

而保守 Q-learning (conservative Q-learning, CQL) 算法思想是在贝尔曼方程上引入一些额外限制

夸克扫描王 极速扫描，就是高效

RL—34.

在普通 Q-Learning 中

$$\hat{Q}^{k+1} \leftarrow \arg\min_Q E_{(s,a)\sim D}\left[\left(Q(s,a) - \hat{B}^\pi \hat{Q}^k(s,a)\right)^2\right]$$

其中 $\hat{B}^\pi$ 是实际计算时策略 π 的贝尔曼算子 $\hat{B}^\pi \hat{Q}^k(s,a) = \max_a \{r + \gamma \Sigma p V\}$

为防止 Q 值在各个状态的过高估计，我们需对某些状态的高 Q 值进行惩罚，考虑一般情况，我们 Q 希望 Q 在某特定分布 $\mu(s,a)$ 上期望值最小，从而上式中 s, a, s', a' 只有 a' 是生成的，可能不在数据集中，于是对 s 按策略 μ 得到的动作进行惩罚 注：argmin 表示对其后所有表达式取最小。

$$\hat{Q}^{k+1} \leftarrow \arg\min_Q \beta E_{s\sim D,\, a\sim\mu(a|s)}[Q(s,a)] + \frac{1}{2} E_{(s,a)\sim D}\left[\left(Q(s,a) - \hat{B}^\pi \hat{Q}^k(s,a)\right)^2\right]$$

其中，β 是平衡因子，通过把 Q 引入公式来降 Q 值，不过若放宽条件，只求 Q 在 $\pi(a|s)$ 上期望 V^π 比真实值小，就可放松上式约束 改为：

$$\hat{Q}^{k+1} \leftarrow \arg\min_Q \beta \cdot \{E_{s\sim D,\, a\sim\mu(a|s)}[Q(s,a)] - E_{s\sim D,\, a\sim\hat{\pi}_\beta(a|s)}[Q(s,a)]\}$$

$$+ \frac{1}{2} E_{(s,a)\sim D}\left[\left(Q(s,a) - \hat{B}^\pi \hat{Q}^k(s,a)\right)^2\right]$$

思路即对符合用于生成数据集的行为策略 π_β 的数据点，可认为 Q 对应些点估值较准，于是这些不必限制让 Q 很小；

将 π_β 写作 $\hat{\pi}_\beta$ 是因为我们无法获知真实行为策略，只能通过数据集中已有的数据近似得到，可证当 $\mu=\pi$ 时上式迭代收敛得到的函数 Q 真不是每一点都真小于真实值，但期望是小于真实值的，即 $E_{\pi(a|s)}[\hat{Q}^\pi(s,a)] \le V^\pi(s)$

但一大问题：计算开销太大，当令 $\mu=\pi$ 时，Q 迭代每一步，真法都要对 $\hat{\pi}^k$ 做完整离线策略评估来计算 argmin，进行策略迭代，而离线策略评估很耗时，既然 π 与 Q 强相关，是由 Q 最大动作衍生出来的，则可用使 Q 取最大值的 μ 来近似 π

即 $\pi \approx \max_\mu E_{s\sim D,\, a\sim\mu(a|s)}[Q(s,a)]$ 拟合最大时的动作分布。

为防过拟合，再加上正则项 $R(\mu)$，采用和一个先验策略 $\rho(a|s)$ 的 KL 距离即 $R(\mu) = -D_{KL}(\mu, \rho)$，取 ρ 为均匀分布 $U(a)$ 即可

于是通过化简可去除式中的 μ.

夸克扫描王
极速扫描，就是高效

RL —— 35.

第19章 目标导向的强化学习.

19.1 简介.

可以学习一个策略，使其在不同目标条件下奏效.

HER、GoRL.…

19.2 问题定义.

GoRL是将元组扩充 $<S, A, P, r_g, G, \phi>$ 来定义MDP.

S：状态空间　A：动作空间.　P：状态转移函数.

G：目标空间　ϕ：将状态s从状态空间映射为目标空间内的一个目标g的函数.

r_g：奖励函数（与目标g有关）.

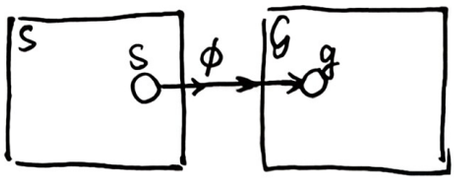

$$r_g(s_t, a_t, s_{t+1}) = \begin{cases} 0 & \|\phi(s_{t+1}) - g\|_2 \le \delta_g \\ -1 & \text{otherwise} \end{cases}$$

其中δ_g为较小的值，表示到目标附近就不会受到-1惩罚.

目标导向学习中，由于对不同目标，奖励函数不同，状态价值函数$V(s,g)$也是基于目标的，$Q(s,a,g)$同理，

优化目标即为使目标函数最大化：（优化策略$\pi(a|s,g)$

$$E_{(s_0,g)\sim\nu_0}[V^{\pi}(s_0,g)]$$

其中ν_0为环境中初始状态和目标g的联合分布

19.3 HER算法.

根据定义，目标导向强化学习的奖励经往十分稀疏，训练初期难以完成目标而只得到-1的奖励，算法训练速度慢

⟶ 提出事后经验回放算法（hindsight experience reply，HER）

夸克扫描王
极速扫描，就是高效

RL ———— 36. 视失败路径为新目标下的成功路径进行训练

初始化策略 π 的参数 θ；初始化经验回放池 R.

for 序列 $e=0 \to E$.

- 根据环境给予的目标 g 和初始状态 s_0，使用 π 在环境采样得到轨迹 $\{s_0, a_0, r_0, \cdots s_T, a_T, r_T, s_{T+1}\}$ 将其以 (s, a, r, s', g) 形式存入 R 中.
- 从 R 中采样 N 个 (s, a, r, s', g) 元组.
- 对这些元组，选择状态 s''，将其映射为新目标 $g' = \phi(s'')$，并计算新奖励值 $r' = r_{g'}(s, a, s')$，用新数据 (s, a, r', s', g') 替换原先元组
- 用新元组对 π 进行训练

end for

※ 此处策略优化算法可任选，如 DQN, DDPG 等.

夸克扫描王
极速扫描，就是高效

RL—37.

第20章 多智能体强化学习

先前介绍的单智能体算法强化学习算法，基本假设是动态环境是稳态的，即状态转移概率和奖励函数不变。而若环境中还有其他智能体在交互和学习，即多智能体强化学习。

对每个智能体视角下，环境是非稳态的

20.2 问题建模

多智能体环境用多元组 (N, S, A, R, P)，其中 N 是智能体的数目，

$S = S_1 \times \cdots \times S_N$ 是所有智能体的状态集合，$A = A_1 \times \cdots \times A_N$ 是～动作集合，

$R = r_1 \times \cdots \times r_N$ 是～奖励函数集合，P 是环境状态转移概率。

20.3 多智能体强化学习的基本求解范式

完全中心化，将所有智能体聚合在一起当一个全局的超级状态，

→显然无法扩展到智能体数量很多或环境很大的情况，会维度爆炸

完全去中心化，每个智能体用一个单智能体强化学习算法学习。

→环境非稳态，收敛性难以保证，

半中心化？检索所有状态发给每个智能体临近的智能体，再让其小范围完全中心化

20.4 IPPO算法 (independent PPO)

对 N 个智能体，初始化各自策略及价值函数

for 训练轮数 $k = 0, 1, 2 \cdots$ do.

所有智能体在环境中交互分别就各自一条轨迹数据。

每个智能体，当前价值函数用 GAE 计算优势函数的估计。

每个智能体，最大化PPO-截断的目标来更新其策略。

每个智能体，通过带均方误差损失函数优化其价值函数。

end for.

夸克扫描王
极速扫描，就是高效

RL-38

第21章 多智能体强化学习进阶

21.1 简介

简介：中心化训练，去中心化运作

(centralized training with decentralized execution, CTDE)

指在训练中用一些全局信息，但在执行时不使用这些信息

- 基于值函数的方法：VDN、QMIX …
- 基于Actor-Critic方法：MADDPG、COMA …

21.2 MADDPG算法

multi-agent DDPG，MADDPG。多智能体DDPG算法。

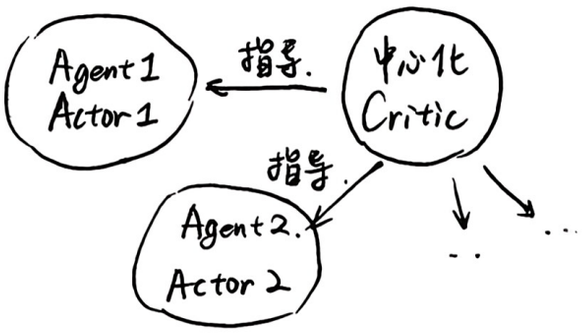

CTDE算法应用场景可建模为部分可观测马尔可夫博弈。

~~用S代表~~

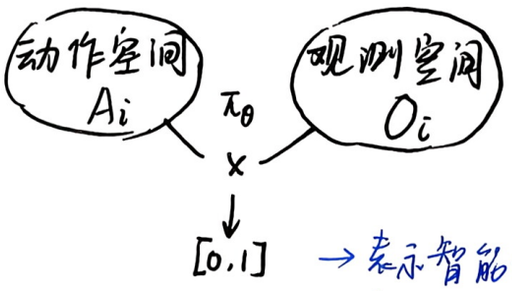

→表示智能体在每个观测下采取各个动作的概率

S表示所有智能体所有可能的状态空间(全局信息)。

环境状态转移函数为 $T: S \times A_1 \times \cdots \times A_N \to$ [redacted] $\mathcal{P}(S)$

每个智能体奖励函数为 $r_i: S \times A \to R$

每个 ～ 从全局状态得到的部分观测信息为 $o_i: S \to O_i$

初始状态分布为 $\rho: S \to [0,1]$

每个智能体目标是最大化期望奖励 $E[\sum_{t=0}^{T} \gamma^t r_i^t]$

夸克扫描王
极速扫描，就是高效

RL——39.

考虑有N个智能体博弈，每个智能体Critic部分能获得其他智能体策略信息，每个智能体策略参数为 $\theta=\{\theta_1,\theta_2,\cdots\theta_N\}$，记策略集合为 $\pi=\{\pi_1,\pi_2,\cdots\pi_N\}$

$$\nabla_{\theta_i} J(\theta_i)=E_{s\sim p^{\mu},a\sim\pi_i}\left[\nabla_{\theta_i}\log\pi_i(a_i|o_i)\,Q_i^{\pi}(x,a_1,\cdots,a_N)\right]$$

$x=(o_1,\cdots,o_N)$ 包含所有智能体的观测.

对于确定性策略，考虑N个连续策略 μ_{θ_i}，可得DDPG梯度公式.

$$\nabla_{\theta_i} J(\mu_i)=E_{x\sim D}\left[\nabla_{\theta_i}\mu_i(o_i)\nabla_{a_i}Q_i^{\mu}(x,a_1,\cdots,a_N)\big|_{a_i=\mu_i(o_i)}\right]$$

夸克扫描王
极速扫描，就是高效

POMDP (Partially Observable Markov Decision Process)

部分可观测 MDP

1、agent 根据过去的动作 a 和观测 o 的历史信息做决策.

历史信息：$H_t = \{a_0, o_0, a_1, o_1, \cdots, a_{t-1}, o_t\}$

策略：$\pi(a_t, H_t)$.

优：直观易实现；端到端学习

缺：维度难控；

2. 信念状态 (Belief State) b_t.

① 定义：$b_t(s)$：在 t 时刻，agent 认为自己在状态 s 的概率.

$$\sum_s b_t(s) = 1.$$

② 信念更新 (Belief Update)

贝叶斯定理

$$b_{t+1}(s') = \eta \underbrace{O(o|s',a)}_{\text{修正}} \underbrace{\sum_s P(s'|s,a)\, b_t(s)}_{\text{预测}}$$

归一化

(1) step1 预测：未得到观测 o，根据刚在哪 $b_t(s)$，以及采取了什么动作 a，推测自己可能在哪如 s'

(2) step2 修正：$O(o|s',a)$，若 agent 真处于 s' 且刚执行了动作 a，那其看到 o 的概率有多大

(3) step3 归一化：η 确保所有概率加和为 1

夸克扫描王 极速扫描，就是高效

粒子滤波器

$$b(s) \approx \sum_{i=1}^{N} w_i \cdot \delta_{s_i}(s)$$

粒子 s_i：一个具体的状态假设。（我猜我在这）

权重 w_i：这个假设的可信程度。

N个粒子：N个并行的可能世界。

4.2 三步循环：

1. 预测

对每个粒子猜：$s_i' \sim T(\cdot | s_i, a)$ 按转移概率走一步

2. 更新

对每个粒子 s_i'：$w_i = Z(o | s_i')$ 收到观测后，能解释观测的粒子权重升高，反之降低。

归一化权重：$w_i = \frac{w_i}{\sum w_i}$

3. 重采样

按权重重新采样N个粒子。

- 权重大的粒子 → 复制多份。
- 权重低的粒子 → 被淘汰

所有权重重置为 $\frac{1}{N}$

若不重采样会导致各项权重差距越来越大，最后只剩一个非零，相当于大算力做单点估计

（重采样时机：①. ESS（有效粒子数）衡量：$ESS = \frac{1}{\sum w_i^2}$

②. $ESS < \frac{N}{2}$ 时 触发重采样。

4.3 系统重采样

可否考虑粒子分布自适应。

夸克扫描王
极速扫描，就是高效

CLF 和 CBF 补充.

实现镇定控制的方法	特点
CLF	计算效率高
积分器反步	流程复杂参数难选
SMC	抖振参数难选
结NN的模糊	数据集大,计算复杂度高

实现安全控制的方法	特点
模型检测 (MC)	适用离散系统
可达性分析 (RA)	求解哈密顿-雅可比方程难
模型预测控制 (MPC)	安全控制轨迹难以调节
控制屏障函数 (CBF)	计算效率高.
强化学习 (RL)	大量数据,缺理论保障

基于CLF和CBF实现安全镇定控制的优势:

1. 能把求解安全镇定控制器的问题转化为一个QP问题
2. 是实时轨迹规划器
3. 适用于任意维度非线性系统.

考虑非线性控制仿射系统, $x \in \mathbb{R}^n$, $u \in \mathbb{R}^m$ 是系统状态和输入

$$\dot{x} = f(x) + g(x)u \quad , \quad x(t_0) = x_0$$

$f: \mathbb{R}^n \to \mathbb{R}^n$ 和 $g: \mathbb{R}^n \to \mathbb{R}^{n\times m}$ 是局部Lipschitz连续的

(即 $\|f(x_1) - f(x_2)\| \le L\|x_1 - x_2\|$, 每一点 $x_0 \in$ 定义域 D, 都有一个小邻域满足以上条件. 即每一小块区域内部都有有界斜率)

安全镇定控制问题:

给定安全集 $C \subseteq \mathbb{R}^n$, 给定初始状态和目标状态 $x_0, x_e \in C$, 设计控制器 s.t.

$x(t) \in C \quad \forall t \in [t_0, \infty)$ → 安全目标

$x(t) \to x_e, \quad t \to \infty$ → 镇定目标.

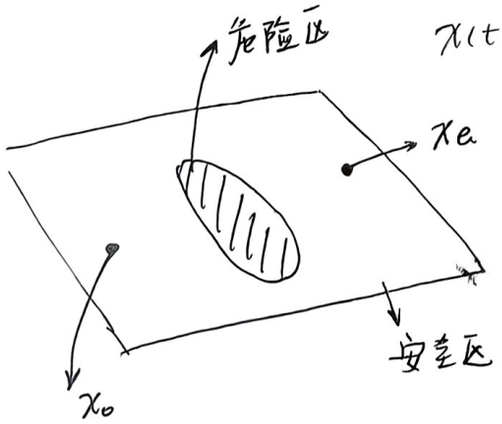

夸克扫描王
极速扫描，就是高效

CBF实现安全控制思路：

找到一个以集合C为0上水平集的函数 $B(x)$，即：

$$C := \{x \in R^n \mid B(x) \geq 0\},$$

要保证函数值一直非负，通过下式实现

$$\dot{B}(x(t)) \geq -\alpha(B(x))$$

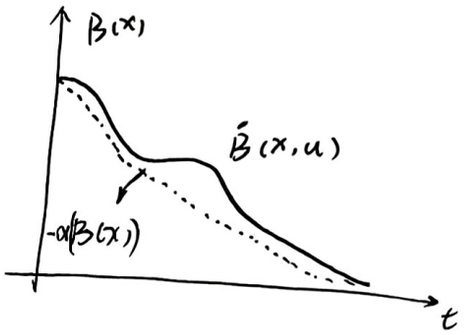

CLF实现镇定控制思路：

找到一个以 x_e 为唯一零点的半正定函数 $V(x)$，并保证函数值一直减小通过下式实现：

$$\dot{V}(x(t)) \leq -\gamma(V(x))$$

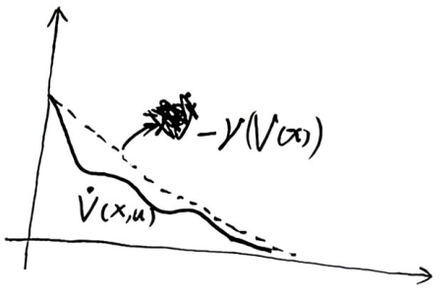

链式求导展开 $\dot{B}(x(t)) = \frac{\partial B(x)}{\partial x} \cdot \frac{\partial x}{\partial t} = \frac{\partial B(x)}{\partial x}(f(x) + g(x)u)$

∴可显式得到控制输入项：$L_f B(x) + L_g B(x) u \geq -\alpha(B(x))$

其中 $L_f B(x) := \left(\frac{\partial B}{\partial x}\right)^T f(x)$，$L_g B(x) := \left(\frac{\partial B}{\partial x}\right)^T g(x)$

将上述约束展开转化为集合形式：

$$u(x) \in K_{cbf}^{\alpha}(x) := \{u \in R^m \mid L_f B(x) + L_g B(x) u \geq -\alpha(B(x))\}$$ CBF约束

$$u(x) \in K_{clf}^{\gamma}(x) := \{u \in R^m \mid L_f V(x) + L_g V(x) u \leq -\gamma(V(x))\}$$ CLF约束

即求解优化问题（二次规划）：

$$\min_{u \in R^m} \|u - u_{ref}\|^2$$

$$s.t.\ u \in K_{clf}^{\gamma}(x) \cap K_{cbf}^{\alpha}(x).$$

其中 u_{ref} 是参考信号。

夸克扫描王
极速扫描，就是高效

如何~~学习~~选取CBF函数

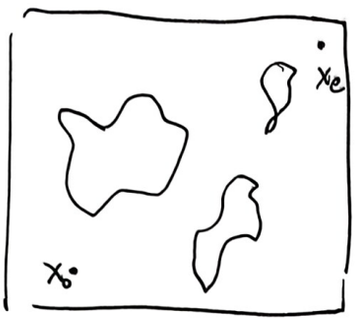

① 学习CBF函数本身：分类/回归方法学习映射

② 学习CBF~~函数~~约束：回归、强化学习

如何解决约束冲突

① 基于优化：引入松弛变量、自适应调节参数…

② 基于闭式控制器：sontag形式、滑模控制器形式… (clf+s)

(switch strategy)

如何耦合CLF、CBF避免冲突？

夸克扫描王
极速扫描，就是高效

补概率论：

① $x \sim N(\mu, \Sigma) \Rightarrow \alpha^T x - \beta \sim N(\alpha^T\mu - \beta, \alpha^T\Sigma\alpha)$

② erf 误差函数.

$erf(x) = \frac{2}{\sqrt{\pi}}\int_0^x e^{-t^2}dt$ $\quad P(-a<Z<a) = erf(\frac{a}{\sqrt{2}})$

③ 分位数.

$\Phi(x_p) = P(X \le x_p) = P$

$\Phi(z) = \frac{1}{2}[1 + erf(\frac{z}{\sqrt{2}})]$

反过来 $z = \sqrt{2}\, erf^{-1}(2p-1)$

④ 方差传播（EKF线性化）

$Var\{\eta(x)\} = \frac{\partial \eta}{\partial x}\Sigma\frac{\partial \eta^T}{\partial x}$

补卡尔曼滤波.

$K = \Sigma^- H^T(H\Sigma^- H^T + R)^{-1}$

Σ^-：预测先验协方差

H：观测矩阵 （$s \to b$ 映射）

R：观测噪声协方差，传感器本身的误差大小.

K 是信任分配权重矩阵，决定更新时听多少传感器，听多少模型预测

拆解式中内容：

① $\Sigma^- H^T$：先验状态不确定性，投影到观测空间的不确定耦合度.

先验越不确定 $\to$ K 越大.

（自己猜的没把握就更相信传感器）

② $H\Sigma^- H^T + R$：预测值在观测维度上的不确定性.

分母越大 $\to$ K 越小.

（权衡是传感器观测测量值可信度）

更后验协方差

$\Sigma^+ = (I - KH)\Sigma^-$

对 $tr(\Sigma^+)$ 关于 K 求导，令梯度为0，得到的即卡尔曼增益公式.

夸克扫描王
极速扫描，就是高效

机会约束

$Pr[\alpha^T x \geq \beta] \geq 1-\delta$

即撞墙概率不超过 δ.

风险度量 (VaR、CVaR)

Var: $VaR_\delta(y) = \inf\{r \mid Pr[y \geq r] \geq 1-\delta\}$

即最差 $(1-\delta)$ 情况的临界值.

CVaR: $CVaR_\alpha(y) = E[y \mid y \leq VaR_\alpha(y)]$

即最差 α 比例的平均值

把安全集搬到信念

安全规范 $\alpha^T x \geq \beta$，要求 $Pr(\alpha^T x \geq \beta) \geq 1-\delta$

利用 VaR 等价关系得到信念空间安全集

$C_b = \{b \mid h_b(b) \geq 0\}$, $h_b(b) = \underbrace{\alpha^T\mu - \beta}_{\text{均值的裕度}} - \underbrace{k_\delta\sqrt{\alpha^T\Sigma\alpha}}_{\text{不确定性的惩罚}}$.

夸克扫描王
极速扫描，就是高效